

GEO GSE54825 重分析：工程化酿酒酵母在纤维二糖与葡萄糖下的转录响应

可复现流程及其与原研究的量化一致性评估

ApaTitee

2026-09-14

目录

1 背景	2
2 研究问题	2
3 数据集	2
4 实验设计	3
5 方法	3
6 质量控制	3
7 定量	4
8 样本水平分析	4
9 差异表达	5
10 功能富集	10
11 生物学解读	13
12 与原研究的一致性	15
13 限制	16
14 工程含义	18
15 可复现性	18
16 结论	19
参考文献	19

1 背景

酿酒酵母 (*Saccharomyces cerevisiae*) 不能天然利用纤维二糖。导入来自粗糙脉孢菌 (*Neurospora crassa*) 的纤维糊精转运蛋白 (cdt-1) 与胞内 β -葡萄糖苷酶 (gh1-1) 可使其在纤维二糖上生长, 但发酵速率仍显著低于葡萄糖 (Galazka 等 2010 年)。本报告重分析的数据集 (GEO [GSE54825](#); (Lin 等 2014 年)) 即针对该工程菌在厌氧条件下纤维二糖与葡萄糖的转录组, 原研究报道了 519 个差异表达基因、线粒体功能激活、氨基酸与硫胺素合成下调, 并给出两条工程线索 (SUT1 过表达、HAP4 缺失)。

原研究使用商业软件 (CLC Genomics Workbench 6.5)、私有参考体系与现已非标准的统计框架 (Baggerley's test)。本报告用现代、完全脚本化的流程重分析同一批原始数据, 并回答原研究无法回答的问题: 原结果有多少可复现, 又有哪些根本不可评估?

2 研究问题

厌氧指数期、单一碳源条件下, 工程化酿酒酵母在纤维二糖与葡萄糖之间的全局转录差异是什么? 涉及哪些生物学过程? 其中哪些原研究结论可以用独立流程量化复现?

3 数据集

两篇论文及其补充材料共 7 个输入文件以只读方式归档并记录 md5; 测序数据为公开数据, 已与 ENA 公布的 md5 逐一核对。

sample_id	gsm	run	condition	replicate	layout	platform
JCYL001B	GSM1324496	SRR1166442	glucose	1	SE	GAII
JCYL002B	GSM1324497	SRR1166443	glucose	2	SE	GAII
JCYL003B	GSM1324498	SRR1166444	glucose	3	SE	GAII
JCYL001D	GSM1324499	SRR1166445	cellobiose	1	SE	GAII
JCYL002D	GSM1324500	SRR1166446	cellobiose	2	SE	GAII
JCYL003D	GSM1324501	SRR1166447	cellobiose	3	SE	GAII

run	sample_id	condition	file	bytes	md5_self	md5_ena	status
SRR1166442	JCYL001B	glucose	SRR1166442.fastq.gz	1957980073	68e674b8a20e	68e674b8a20e	PASS
SRR1166443	JCYL002B	glucose	SRR1166443.fastq.gz	2168810515	dcc91f003612	dcc91f003612	PASS
SRR1166444	JCYL003B	glucose	SRR1166444.fastq.gz	1601609705	f58e37e44319	f58e37e44319	PASS
SRR1166445	JCYL001D	cellobiose	SRR1166445.fastq.gz	2189433744	a201447b2dda	a201447b2dda	PASS
SRR1166446	JCYL002D	cellobiose	SRR1166446.fastq.gz	1839997905	028b8c4edc3b	028b8c4edc3b	PASS
SRR1166447	JCYL003D	cellobiose	SRR1166447.fastq.gz	1586975675	cbb987dbfaa3	cbb987dbfaa3	PASS

4 实验设计

2 组 × 3 生物学重复，单一批次，厌氧指数期（起始糖 80 g/L，残余糖 ≈ 50 g/L 时取样）。原研究使用非配对两组比较；样本命名（JCYL001B/001D 等）暗示可能存在配对，但公开元数据无法确证。因此主分析采用非配对模型 (~ condition)，并以配对模型 (~ replicate + condition) 作敏感性分析。无 spike-in、无独立批次。

5 方法

步骤	工具、版本与参数
原始数据	ENA FTP 下载；md5 与 ENA 公布值逐一核对
读段 QC	FastQC 0.12.1；fastp 1.3.6（轻度修剪，保留长度 ≥ 36 bp）；MultiQC 1.35
参考（宿主）	RefSeq GCF_000146045.2（S288C R64-1-1，16 条染色体 + 线粒体）；用 gffread 0.12.9 抽取转录本；注释来自 SGD GAF（R64-5-1）
参考（外源）	宿主-载体-插入片段序列由样本 reads 自身裁决重建
定量	Salmon 2.7.0，decoy-aware 索引（k = 31，另做 k = 25 敏感性），-libType A -gcBias -seqBias；片段长度先验设为实测读长（49 bp）
基因水平矩阵	tximport 1.34.0，countsFromAbundance = lengthScaledTPM
差异表达	DESeq2 1.46.0；主模型 ~ condition，敏感性 ~ replicate + condition；apeglm 收缩 LFC 仅用于展示
多重检验	Benjamini-Hochberg
功能富集	clusterProfiler 4.14.0（ORA + GSEA），TERM2GENE 自建；KEGG（sce）结果缓存
报告	Quarto 1.9.38（HTML；PDF 由 LaTeX/xelatex 生成）

阈值：主 DEG 为 BH 校正 $p < 0.05$ 且 $|\log_2FC| > 1$ ；另报告放宽 ($p < 0.1$) 与收紧 ($p < 0.01$ 且 $|\log_2FC| > 1.5$) 两档，以及与原文对齐的一档 ($FDR \leq 0.001$ 且 $|\log_2FC| \geq 1$)。所有阈值判定一律使用未收缩 (**MLE**) **log₂FC**，apeglm 收缩值仅用于排序与作图。富集分析的背景集 (universe) 为检出表达的基因（在 ≥ 3 个样本中 count ≥ 10），共 6049 个。

6 质量控制

2014 年的数据为 Genome Analyzer II 单端 50 bp 读段。FastQC 判定为 Sanger/Illumina 1.9 编码，因此无需 Phred64 处理。轻度修剪保留 2.386 亿 reads 中的 95.1%，Q30 由 0.88-0.93 提升至 0.93-0.96；adapter 残留可忽略（修剪后约 150 reads/样本，0.01%）。

read fate（读数去向）按三级归因：(i) 端到端比对到宿主基因组 + 外源转录本（94.5-95.5%）；(ii) 对未比对部分做局部模式重比对（可回收其中 19.9-22.8%，源于端到端模式偏严与这批较老数据的读段错误）；(iii) 用包含 pRS426 骨架、天然 2μ 质粒与 TruSeq adapter 的诊断参考（再解释残

余的 35.6–40.4%)。仍有 2.2–3.0% (全库口径) 未能归因, 候选原因见“限制”一节。多映射比例为 23.0–24.9%, 主要由 Ty 元件与 rDNA 重复驱动; rDNA 位点是参考中覆盖最深的区域 (RDN25-1 平均深度 23×)。

质粒拷贝数: 工程质粒骨架来源的 reads 在纤维二糖中为 1.65 倍 (每百万读数 10,385 → 17,188), 而天然 2μ 质粒来源的 reads 不变 (3,358 → 3,012)。这独立说明拷贝数效应只发生在工程质粒上。

7 定量

宿主参考与注释已冻结 (RefSeq GCF_000146045.2、SGD 注释发布 R64-5-1, 全部文件记录 md5)。本数据集有两处必须特殊处理:

外源序列与文献所述并不一致。RNA-seq 样本携带的是 pRS426-BT, 其插入片段来自粗糙脉孢菌 cDNA。由 reads 重建的共识序列与 cdt-1 (NCU00801)、gh1-1 (NCU00130) 的公共 CDS 逐位一致 (0 处差异)。补充材料 Figure S8 中发表的密码子优化版本 gh1-1a 在样本中并不存在 (600 万 reads 中仅 2 条命中), 且与天然 CDS 有 25% 的位置不同——若直接用作参考, 外源定量会被静默破坏。C 端标签为 **superfolder GFP**: 共识序列与人源化 EGFP CDS 仅差 7 个核苷酸, 翻译后在 EGFP 骨架上带有全部 6 个 superfolder 替换 (S30R/Y39N/N105T/Y145F/I171V/A206V)。cdt-1 与标签的接头由软剪切 reads 直接读出: …GTTGCT + ATCGAT (ClaI) + GGTAGTGGTAGT (Gly-Ser-Gly-Ser) + GTGAGC…, 与早期工作的克隆策略一致 (Galazka 等 2010 年)。由于外源参考的一部分来自样本 reads 自身, 外源结果只报比值。

线粒体编码基因必须测量而非假设。RefSeq 的 RNA FASTA 不含线粒体蛋白编码 mRNA, 因此改用 gffread 从 GFF 抽取转录本 (6480 条宿主转录本, 含 19 条线粒体 mRNA), 再追加两条外源转录本。

Salmon 的 decoy-aware 索引比率为 80.0–83.5% ($k = 31$); 12 次运行均推断文库类型为非链特异性 (**U**), 与 TruSeq v1 建库一致。定量结果用三种独立方式验证: (i) TPM 与原文 RPKM 在 5796 个基因上 Spearman = 0.880; (ii) 加入或去掉基因组 decoy 对 TPM 的中位影响仅 0.027 个 log2 单位 (5960 个基因中 17 个超过 1); (iii) 两个标尺基因几乎逐位复现原文 (URA3 比值 1.364 vs 1.354; PGK1 比值 0.749 vs 0.745)。

Salmon 2.7.0 (Rust 版) 报告的 **EffectiveLength** 语义异常: 宿主转录本的中位有效长度为长度的 0.465 倍, 外源条目则超过长度的 10 倍。这不影响上述结论——(i)–(iii) 的三项检验与 decoy 对照正是为界定该风险而做, 且外源结论全部基于比值。

8 样本水平分析

item	value
n_genes_used	6049
PC1_var_pct	93.4
PC2_var_pct	2.3
within_glucose_spearman_min	0.9961
within_glucose_spearman_max	0.9974
within_cellobiose_spearman_min	0.9944

within_cellobiose_spearman_max	0.9977
between_condition_spearman_min	0.8855
between_condition_spearman_max	0.8954
separation_verdict	conditions separated on PC1

条件在 PC1 上分离 (93.4% 方差)，组内重复一致性极高 (Spearman ρ 0.994–0.998)，明显高于组间 (0.886–0.895)，支持 H0。

9 差异表达

model	n_tested	n_deg	n_up	n_down	n_transgene
~condition (primary)	6049	644	346	298	2
~condition relaxed	6049	4583	2325	2258	2
~condition stringent	6049	363	207	156	2
~condition FDR $\leq$ 0.001 & LFC $\geq$ 1	6049	632	341	291	2
~replicate+condition (paired)	6049	643	347	296	2

主模型得到 **644** 个 **DEG** (上调 346、下调 298)；与原文阈值对齐的一档得到 **632** 个 (341/291)。配对敏感性模型得到 643 个 DEG，与主模型几乎完全一致 (Jaccard 0.986；方向一致率 100%；log2FC 的 Pearson 相关 1.0000)，说明结论不依赖配对假设。模型诊断显示无系统性反保守，仅 1 个基因超过 Cook's distance 阈值。




图 1: PCA of VST-normalised expression. Conditions separate on PC1 (93.4% of variance); within-condition replicates are tightly clustered (Spearman rho 0.994-0.998).




图 2: Sample-to-sample Spearman correlation of VST-normalised expression.

Volcano plot (n = 6048 genes; 644 DEGs at padj < 0.05 and |log2FC| >




图 3: Volcano plot of the primary model (~ condition). Thresholds: BH-adjusted $p < 0.05$ and $|\log_2\text{FC}| > 1$; fold changes are unshrunk (MLE) values, which are the values used for all thresholding.




Fig 4: Row-scaled VST expression of the 50 most significant DEGs.




图 5: p-value distribution of the primary model (no systematic anti-conservatism; Cook's cutoff exceeded by 1 of 6049 genes).

10 功能富集

comparison	Description	GeneRatio	pvalue	p.adjust	Count
primary_DOWN_GOslim	amino acid metabolic process [GO:0006520]	51/294	0.0e+00	0.00e+00	51
primary_DOWN_GOslim	small molecule metabolic process [GO:0044281]	86/294	0.0e+00	0.00e+00	86
primary_DOWN_GOslim	sulfur compound metabolic process [GO:0006790]	35/294	0.0e+00	0.00e+00	35
primary_DOWN_GOslim	cytosol [GO:0005829]	88/294	0.0e+00	0.00e+00	88
primary_DOWN_GOslim	transmembrane transporter activity [GO:0022857]	42/294	0.0e+00	4.00e-07	42
primary_DOWN_GOslim	vitamin metabolic process [GO:0006766]	14/294	0.0e+00	4.00e-07	14
primary_DOWN_GOslim	monoatomic ion transport [GO:0006811]	17/294	2.1e-06	4.31e-05	17
primary_DOWN_GOslim	transmembrane transport [GO:0055085]	31/294	2.2e-06	4.31e-05	31
primary_UP_GOslim	respiratory chain complex [GO:0098803]	36/316	0.0e+00	0.00e+00	36
primary_UP_GOslim	generation of precursor metabolites and energy [GO:0006091]	50/316	0.0e+00	0.00e+00	50
primary_UP_GOslim	cellular respiration [GO:0045333]	32/316	0.0e+00	0.00e+00	32
primary_UP_GOslim	mitochondrion [GO:0005739]	120/316	0.0e+00	0.00e+00	120
primary_UP_GOslim	proton-transporting ATP synthase complex [GO:0045259]	14/316	0.0e+00	0.00e+00	14
primary_UP_GOslim	oxidoreductase activity [GO:0016491]	52/316	0.0e+00	0.00e+00	52
primary_UP_GOslim	transmembrane transporter activity [GO:0022857]	54/316	0.0e+00	0.00e+00	54
primary_UP_GOslim	respiratory chain complex III [GO:0045275]	9/316	0.0e+00	0.00e+00	9
threshold_matched_DOWN_GOslim	amino acid metabolic process [GO:0006520]	51/289	0.0e+00	0.00e+00	51
threshold_matched_DOWN_GOslim	small molecule metabolic process [GO:0044281]	86/289	0.0e+00	0.00e+00	86
threshold_matched_DOWN_GOslim	sulfur compound metabolic process [GO:0006790]	35/289	0.0e+00	0.00e+00	35
threshold_matched_DOWN_GOslim	cytosol [GO:0005829]	88/289	0.0e+00	0.00e+00	88
threshold_matched_DOWN_GOslim	transmembrane transporter activity [GO:0022857]	42/289	0.0e+00	2.00e-07	42
threshold_matched_DOWN_GOslim	vitamin metabolic process [GO:0006766]	14/289	0.0e+00	4.00e-07	14
threshold_matched_DOWN_GOslim	transmembrane transport [GO:0055085]	31/289	1.5e-06	3.22e-05	31
threshold_matched_DOWN_GOslim	monoatomic ion transport [GO:0006811]	17/289	1.6e-06	3.22e-05	17
threshold_matched_UP_GOslim	respiratory chain complex [GO:0098803]	36/315	0.0e+00	0.00e+00	36
threshold_matched_UP_GOslim	generation of precursor metabolites and energy [GO:0006091]	50/315	0.0e+00	0.00e+00	50
threshold_matched_UP_GOslim	cellular respiration [GO:0045333]	32/315	0.0e+00	0.00e+00	32
threshold_matched_UP_GOslim	mitochondrion [GO:0005739]	120/315	0.0e+00	0.00e+00	120
threshold_matched_UP_GOslim	proton-transporting ATP synthase complex [GO:0045259]	14/315	0.0e+00	0.00e+00	14
threshold_matched_UP_GOslim	oxidoreductase activity [GO:0016491]	52/315	0.0e+00	0.00e+00	52
threshold_matched_UP_GOslim	transmembrane transporter activity [GO:0022857]	54/315	0.0e+00	0.00e+00	54
threshold_matched_UP_GOslim	respiratory chain complex III [GO:0045275]	9/315	0.0e+00	0.00e+00	9




Figure 6: MA plot with apegglm-shrunken log2FC (display only; thresholding uses MLE values).




图 7: GO slim over-representation analysis (top 10 terms per gene set; BH-adjusted p).

ID	Description	GeneRatio	pvalue	p.adjust	Count
sce00190	Oxidative phosphorylation - <i>Saccharomyces cerevisiae</i> (budding yeast)	44/250	0.00e+00	0.00e+00	44
sce01110	Biosynthesis of secondary metabolites - <i>Saccharomyces cerevisiae</i> (budding yeast)	96/250	0.00e+00	0.00e+00	96
sce01230	Biosynthesis of amino acids - <i>Saccharomyces cerevisiae</i> (budding yeast)	43/250	0.00e+00	0.00e+00	43
sce00270	Cysteine and methionine metabolism - <i>Saccharomyces cerevisiae</i> (budding yeast)	19/250	0.00e+00	6.00e-07	19
sce00340	Histidine metabolism - <i>Saccharomyces cerevisiae</i> (budding yeast)	10/250	1.00e-07	2.10e-06	10
sce00670	One carbon pool by folate - <i>Saccharomyces cerevisiae</i> (budding yeast)	12/250	1.70e-06	2.32e-05	12
sce01200	Carbon metabolism - <i>Saccharomyces cerevisiae</i> (budding yeast)	29/250	3.20e-06	3.86e-05	29
sce00920	Sulfur metabolism - <i>Saccharomyces cerevisiae</i> (budding yeast)	9/250	5.00e-06	5.21e-05	9
sce01210	2-Oxocarboxylic acid metabolism - <i>Saccharomyces cerevisiae</i> (budding yeast)	15/250	1.03e-05	9.65e-05	15
sce00220	Arginine biosynthesis - <i>Saccharomyces cerevisiae</i> (budding yeast)	10/250	1.29e-05	1.00e-04	10

ID	Description	setSize	NES	pvalue	p.adjust
amino acid metabolic process	amino acid metabolic process	222	-2.65	0	0
carboxylic acid biosynthetic process	carboxylic acid biosynthetic process	181	-2.65	0	0
organic acid biosynthetic process	organic acid biosynthetic process	181	-2.65	0	0
alpha-amino acid metabolic process	alpha-amino acid metabolic process	159	-2.66	0	0
L-amino acid metabolic process	L-amino acid metabolic process	147	-2.64	0	0
proteinogenic amino acid metabolic process	proteinogenic amino acid metabolic process	147	-2.64	0	0
small molecule biosynthetic process	small molecule biosynthetic process	343	-2.32	0	0
amino acid biosynthetic process	amino acid biosynthetic process	119	-2.65	0	0
sulfur compound metabolic process	sulfur compound metabolic process	146	-2.59	0	0
organic acid metabolic process	organic acid metabolic process	354	-2.23	0	0

原文使用 FunSpec + Bonferroni(p 0.01); 本重分析使用 clusterProfiler + Benjamini-Hochberg, 并自建 GO slim 映射 (SGD go_slim_mapping.tab) 以及经 true-path-rule 传播到祖先术语的全 GO 注释。富集过程的身份与方向复现了原文结论: 上调基因由呼吸链、氧化磷酸化、ATP 合成、线粒体与 TCA 循环相关术语主导; 下调基因由氨基酸生物合成 (Met、Cys、Arg、His) 与硫胺素 (维生素 **B1**) 生物合成主导; KEGG 结果同向 (氧化磷酸化、氨基酸生物合成、半胱氨酸与甲硫氨酸代谢、组氨酸代谢)。

一项原研究未报告的观察：GSEA 负向最强的信号集中在 Ty 逆转座子相关术语。由于这些序列高度多映射，该结果仅谨慎陈述，且不用于任何生物学结论。

11 生物学解读

hypothesis	subtests	replicated	verdict
H0	1	1	replicated
H1	5	5	replicated
H2	6	6	replicated
H3	3	1	replicated (partial activation, as originally reported)
H4	1	1	replicated
H5	2	1	replicated
H6	1	1	replicated
H7	1	1	replicated
H8	3	3	replicated
H9	1	1	replicated

hypothesis	n_genes	mean_log2FC	wilcoxon_p	n_deg_in_set	fisher_p	verdict
H0: global transcriptome separates by carbon..	6049	NA	NA	NA	NA	replicated
H7: transgene mRNA is higher on cellobiose (..	2	NA	NA	2	NA	replicated
H1: TCA cycle	28	0.859	1.94e-04	11	8.11e-05	replicated
H1: electron transport chain	40	1.550	0.00e+00	29	0.00e+00	replicated
H1: oxidative phosphorylation	37	1.790	0.00e+00	29	0.00e+00	replicated
H1: ATP synthesis coupled proton transport	16	1.790	3.05e-05	15	0.00e+00	replicated
H1: respiratory chain complex	45	1.910	0.00e+00	38	0.00e+00	replicated
H2: cellular amino acid biosynthetic process	119	-0.818	0.00e+00	50	0.00e+00	replicated
H2: methionine biosynthetic process	26	-1.330	1.91e-05	13	7.00e-07	replicated
H2: cysteine biosynthetic process	5	-2.170	6.25e-02	3	1.00e-02	replicated
H2: arginine biosynthetic process	13	-1.480	1.22e-03	10	0.00e+00	replicated
H2: histidine biosynthetic process	8	-1.060	1.56e-02	6	3.23e-05	replicated
H2: thiamine biosynthetic process	16	-1.220	2.69e-03	7	7.64e-04	replicated
H3: PKA pathway	10	0.448	3.91e-03	0	6.13e-01	replicated
H3: Snf3-Rgt2-Rgt1	5	0.047	1.00e+00	2	9.06e-02	not_replicated
H3: Snf1-Mig1	5	-0.054	8.12e-01	1	4.30e-01	not_replicated
H4: hexose transporters	11	-0.138	9.66e-01	6	4.13e-04	replicated
H5: SUT1 + ERG sterol genes	21	0.058	7.85e-01	2	1.00e+00	not_replicated
H5: DAN/TIR/PAU family	26	0.580	3.34e-02	12	6.00e-06	replicated
H6: storage carbon & gluconeogenesis	8	1.120	2.34e-02	2	2.07e-01	replicated
H9: ribosomal protein genes (growth-rate pro..	132	0.337	0.00e+00	1	5.00e-07	replicated
H8: YGL162W (engineering candidate from H3/H5)	1	2.140	0.00e+00	NA	NA	replicated (differentially expressed)
H8: YKL109W (engineering candidate from H3/H5)	1	2.630	0.00e+00	NA	NA	replicated (differentially expressed)
H8: YKR034W (engineering candidate from H3/H5)	1	1.220	0.00e+00	NA	NA	replicated (differentially expressed)

estimator	gene	glucose_value	cellobiose_value	FC	note
salmon_CPM	cdt-1EGFP	2260.0	4530.0	2.010	mean of reads per million mapped (salmon)
salmon_CPM	gh1-1	1400.0	3260.0	2.320	mean of reads per million mapped (salmon)
salmon_TPM	cdt-1EGFP	26.8	75.7	2.820	TPM (length-normalised, salmon)
salmon_TPM	gh1-1	26.4	84.4	3.190	TPM (length-normalised, salmon)
URA3_proxy	URA3(YELO21W)	432.0	589.0	1.360	plasmid copy-number proxy (original anchor 1.354)
PGK1_control	PGK1(YCR012W)	NA	NA	0.749	same-promoter control (original anchor 0.745)
URA3_normalized	cdt-1EGFP	NA	NA	1.470	= CPM_FC / URA3_FC
URA3_normalized	gh1-1	NA	NA	1.700	= CPM_FC / URA3_FC
original_RPKM	cdt-1EGFP	877.0	1640.0	1.870	original study anchor (Dataset S1)
original_RPKM	gh1-1	932.0	2010.0	2.160	original study anchor (Dataset S1)
reads_1M_subsample	cdt-1	1390.0	2630.0	1.880	adjudication experiment, bowtie2 read counts (PLAN 3.4.3)
reads_1M_subsample	gh1-1	1200.0	2680.0	2.220	adjudication experiment, bowtie2 read counts (PLAN 3.4.3)

九条预注册假设均以集合水平统计量判定（Wilcoxon 符号秩检验、Fisher 精确检验的差异表达富集、集合内 DEG 计数）。全部获得支持：




图 8: Independent estimators of the transgene fold change (cellobiose/glucose) and of the plasmid copy-number proxy URA3. Read-based estimators (1.89-2.01 for cdt-1EGFP, 2.22-2.32 for gh1-1) bracket the values reported in the original study (1.87 and 2.16).

- **H1** (线粒体功能激活) 在五个独立基因集上复现 (呼吸链复合物 +1.91; ATP 合成 +1.79, 16 个基因中 15 个为 DEG; 氧化磷酸化 +1.79; 电子传递链 +1.55; TCA 循环 +0.86)。线粒体编码基因被排除在该检验之外 (见“限制”)。
- **H2** (氨基酸与硫胺素合成下调) 在全部六个子集复现, 包括硫胺素生物合成 (−1.22; 16 个中 7 个 DEG, Fisher $p = 2.7 \times 10^{-3}$)。
- **H3** (葡萄糖信号通路仅部分激活) 在原研究所述的意义上成立: PKA 集合仅小幅偏移 (+0.45), Rgt1 与 Snf1-Mig1 集合无系统性偏移。
- **H4** (己糖转运蛋白家族重排) 整体无方向性偏移 (平均 log2FC −0.14), 但 11 个转运蛋白中有 6 个为 DEG, 属“家族级重排”而非一致响应。
- **H5-H8** 均复现, 包括工程线索: SUT1 +1.77、HAP4 +2.61、DAL80 +1.22。
- **H9** (生长速率/葡萄糖阻遏混杂): 核糖体蛋白基因集 (132 个) 整体 +0.34 ($p = 1.4 \times 10^{-21}$), 说明混杂确实存在且可测量; 其方向提示主轴是葡萄糖阻遏解除而非“慢生长”——因为酵母中核糖体蛋白基因通常随生长速率升高而上调。

12 与原研究的一致性

metric	value
genes_comparable_FC	5770.000
spearman_log2FC	0.973
pearson_log2FC	0.840
our_DEG_threshold_matched	632.000
original_DEG	519.000
overlap	496.000
jaccard	0.757
hypergeometric_p	0.000
direction_concordance_in_overlap	1.000
background_genes	5780.000

item	reason
mtDNA-encoded gene expression	poly-A selection captures yeast mitochondrial transcripts
absolute transgene abundance	the tag/junction part of the transgene reference is derived from the host genome
absolute RPKM/TPM matching the original	CLC multi-mapping and 'By totals' RPKM are not reproducible
cross-tool mapping statistics	original 92.3/83.4/76.3% were produced by CLC's internal mapping
transgene C-terminal His6 cleavage state	requires protein-level data, out of scope

item	value	note
dataset_s1_rows_total	6351	Dataset S1 data rows (including the 2 transgene entries)
dataset_s1_host_genes	6349	host gene entries
dataset_s1_transgenes	2	transgene entries (cdt-1EGFP, gh1-1)
dataset_s2_deg_rows	519	the 519 DEGs reported in the original study
dataset_s2_deg_transgenes	1	transgene entries within the 519 (gh1-1)
dataset_s2_tf_rows	19	19 transcription factors

dataset_s2_grn_rows	7	7 GRN regulatory genes
dataset_s3_go_terms_up	12	GO terms on the UP side
dataset_s3_go_terms_down	16	GO terms on the DOWN side
dataset_s3_up_genes	244	UP gene count declared in the Dataset S3 section header
dataset_s3_down_genes	256	DOWN gene count declared in the Dataset S3 section header
dataset_s3_notfound_up	3	genes not mapped by FunSpec on the UP side
dataset_s3_notfound_down	0	genes not mapped by FunSpec on the DOWN side
check_sum_of_parts	503	reconciliation: UP + DOWN + not-found on both sides
check_gap_vs_519	16	gap versus 519; explained in the report (the transgene gh1-1

在所有可比较的层面，一致性都很高：

层面	结果
逐基因 log2FC (5771 个基因)	Spearman 0.973 , Pearson 0.840
DEG 重叠 (632 vs 原文 519)	重叠 496 , Jaccard 0.757, 超几何 $p \approx 0$
重叠内方向一致率	100%
数字对账	原文 519 = 244 上调 + 256 下调 + 18 未映射 + <i>gh1-1</i> (无 GO 注释)
外源倍数变化 (比值口径)	1.89-2.01 (<i>cdt-1EGFP</i>)、2.22-2.32 (<i>gh1-1</i>), 原文为 1.87 与 2.16
质粒拷贝数代理 (URA3)	1.364, 原文 1.354

RPKM/TPM 的绝对值无法与原文一致：CLC 内部的多重比对处理在 CLC 之外不可复现（原文也仅有 76.3% 唯一比对），92.3/83.4/76.3% 这类比例是软件特有量。可复现的是基因水平趋势，而这一趋势几乎被逐位复现。

13 限制

- 富集框架与原文不同 (clusterProfiler + BH vs FunSpec + Bonferroni)，因此富集 p 值不可直接比较，可比较的是富集过程的身份与方向。
- 线粒体编码基因不可评估：poly-A 富集对其捕获效率极低（每百万读数仅 5-18 条 chrM reads；19 个线粒体基因无一达到 $1\times$ 覆盖）。这与芽殖酵母线粒体 mRNA 缺乏可供 oligo(dT) 捕获的长 poly(A) 尾一致 (Chang 和 Tong 2012 年)。因此 H1 只在核编码线粒体功能基因范围内检验。
- 外源丰度存在一定循环性：标签与接头序列来自样本 reads 自身。比值对此稳健（两个条件使用同一参考、偏差同向），但绝对 TPM 不可独立验证。
- 质粒拷贝数在条件间不同 (URA3 1.364 $\times$ ；骨架 reads 1.65 $\times$)。用代理指标归一化后，外源比值降至 1.47 (*cdt-1EGFP*) 与 1.70 (*gh1-1*)，即部分升高来自拷贝数而非转录调控。
- 质粒终止子/启动子串扰对 PGK1 与 CYC1 影响很小但无法完全分离；CYC1 本身是线粒体激活相关基因，在原文数据中变化 2.5 倍。
- 未比对 **reads** 仅部分解释：仍有 2.2-3.0% (全库口径) 未归因，候选原因包括 GA II 数据的读段错误、非酵母污染、R64 组装中塌缩或缺失的区域（亚端粒/Y' 元件），以及在任何参考中都不存在的嵌合 reads（启动子-CDS、CDS-终止子）。
- 无 **spike-in**、无独立批次、**n = 3**，限制绝对定量与方差估计；6 个样本下替代变量方法不适用。




图 9: Per-gene log2FC agreement with the original study (Spearman = 0.973 over 5771 genes).




图 10: Precision/recall of the original 519 DEGs as a function of threshold.

- **Salmon 2.7.0** 的 **EffectiveLength** 语义异常（见“定量”），已证明结论对其不敏感，但绝对 TPM 不宜过度解读。
- 配对关系无法确证，配对模型仅作为敏感性分析。

14 工程含义

本重分析复现了原研究的两条工程线索并给出量化语境：SUT1 (+1.77) 与 HAP4 (+2.61) 是最强烈诱导的转录因子之列，DAL80 (+1.22) 同样显著。需要注意 HAP4 在纤维二糖中上调，而其缺失改善发酵，说明其调控作用非单调——这提醒不能把转录方向直接当作工程指令。响应主体集中在酵母线粒体功能与氨基酸/硫胺素途径，提示面向辅因子与前体供给（而非仅糖转运）的工程策略更具前景。

15 可复现性

本报告全部内容由 scripts/ 下的编号脚本生成：

```
conda env create -f environment.yml && conda activate yeast-cellobiose-rnaseq
bash run_all.sh # 幂等；已完成步骤自动跳过
```

凭证	位置
原始数据校验（自算 + ENA 公布）	checksums/
参考与注释版本	refs/VERSIONS.md
全部非公开序列的来源	refs/custom/PROVENANCE.md
序列裁决与接头证据	refs/custom/{sequence_adjudication.tsv, junctions.tsv}
环境锁（conda-explicit + R 包快照）	env/
参数与范围决策	docs/decisions/
阶段验收记录	docs/acceptance/

R 环境以 conda 而非 renv 锁定，因为在本机配置下 renv 的项目激活会遮蔽 conda 库（见 docs/decisions/r_environment.md）。

16 结论

用独立、完全脚本化的流程重分析 GSE54825，在“可比较”的层面上几乎完整复现了原研究：逐基因倍数变化的排序一致性 97.3%，找回原文 519 个 DEG 中的 496 个，方向一致率 100%，富集过程一致。另有三点超出原文：外源参考序列由数据重建并验证（发现已发表的密码子优化版本 gh1-1a 并非本样本中的等位基因）；量化了质粒拷贝数对外源信号的贡献；把“生长速率/葡萄糖阻遏”混杂从假设变为测量。无法消除的限制——线粒体编码基因、外源绝对丰度、CLC 特有的映射统计——均被明确声明。

参考文献

- Chang, David D., 和 Amy H. Tong. 2012 年. 《Mitochondrial poly(A) polymerase and polyadenylation》. *Biochimica et Biophysica Acta* 1819: 945~50. <https://doi.org/10.1016/j.bbagr.2012.01.008>.
- Galazka, Jonathan M., Chaoguang Tian, William T. Beeson, Bruno Martinez, N. Louise Glass, 和 Jamie H. D. Cate. 2010 年. 《Cellodextrin transport in yeast for improved biofuel production》. *Science* 330 (6000): 84~86. <https://doi.org/10.1126/science.1192838>.
- Lin, Yuping, Kulika Chomvong, Ligia Acosta-Sampson, 等. 2014 年. 《Leveraging transcription factors to speed cellobiose fermentation by *Saccharomyces cerevisiae*》. *Biotechnology for Biofuels* 7: 126. <https://doi.org/10.1186/s13068-014-0126-6>.