

GEO GSE54825 重分析：工程化酿酒酵母在纤维二糖与葡萄糖下的转录响应

可复现流程及其与原研究的量化一致性评估

ApaTitee

2026-09-14

目录

1 背景	1
2 研究问题	2
3 数据集	2
4 实验设计	2
5 方法	2
6 质量控制	3
7 定量	3
8 样本水平分析	4
9 差异表达	5
10 功能富集	9
11 生物学解读	12
12 与原研究的一致性	14
13 限制	17
14 工程含义	17
15 可复现性	18
16 结论	18
参考文献	18
参考文献	18

1 背景

酿酒酵母 (*Saccharomyces cerevisiae*) 不能天然利用纤维二糖。导入来自粗糙脉孢菌 (*Neurospora crassa*) 的纤维糊精转运蛋白 (*cdt-1*) 与胞内 β -葡萄糖苷酶 (*gh1-1*) 可使其在纤维二糖上生长，但发酵速率仍显著低于葡萄糖 [1]。本报告重分析的数据集 (GEO GSE54825; [2]) 即针对该工程菌在厌氧条件下纤维二糖与葡萄糖的转录组，原研究报道了 519 个差异表达基因、线粒体功能激活、氨基酸与硫胺素合成下调，并给出两条工程线索 (*SUT1* 过表达、*HAP4* 缺失)。

原研究使用商业软件 (CLC Genomics Workbench 6.5)、私有参考体系与现已非标准的统计框架 (Baggerley's test)。本报告用现代、完全脚本化的流程重分析同一批原始数据，并回答原研究无法回答的问题：原结果有多少可复现，又有哪些根本不可评估？

2 研究问题

厌氧指数期、单一碳源条件下，工程化酿酒酵母在纤维二糖与葡萄糖之间的全局转录差异是什么？涉及哪些生物学过程？其中哪些原研究结论可以用独立流程量化复现？

3 数据集

两篇论文及其补充材料共 7 个输入文件以只读方式归档并记录 md5；测序数据为公开数据，已与 ENA 公布的 md5 逐一核对。

```
#table( columns: 7, table.header([sample_id], [gsm], [run], [condition], [replicate], [layout],  
[platform]), [JCYL001B], [GSM1324496], [SRR1166442], [glucose], [1], [SE], [GAII], [JCYL002B],  
[GSM1324497], [SRR1166443], [glucose], [2], [SE], [GAII], [JCYL003B], [GSM1324498],  
[SRR1166444], [glucose], [3], [SE], [GAII], [JCYL001D], [GSM1324499], [SRR1166445], [cellobiose],  
[1], [SE], [GAII], [JCYL002D], [GSM1324500], [SRR1166446], [cellobiose], [2], [SE], [GAII],  
[JCYL003D], [GSM1324501], [SRR1166447], [cellobiose], [3], [SE], [GAII], )
```

```
#table( columns: 8, table.header([run], [sample_id], [condition], [file], [bytes],  
[md5_self], [md5_ena], [status]), [SRR1166442], [JCYL001B], [glucose], [SRR1166442.fastq.gz],  
[1.96e+09], [68e674b8a20e], [68e674b8a20e], [PASS], [SRR1166443], [JCYL002B], [glucose],  
[SRR1166443.fastq.gz], [2.17e+09], [dcc91f003612], [dcc91f003612], [PASS], [SRR1166444],  
[JCYL003B], [glucose], [SRR1166444.fastq.gz], [1.60e+09], [f58e37e44319], [f58e37e44319],  
[PASS], [SRR1166445], [JCYL001D], [cellobiose], [SRR1166445.fastq.gz], [2.19e+09],  
[a201447b2dda], [a201447b2dda], [PASS], [SRR1166446], [JCYL002D], [cellobiose],  
[SRR1166446.fastq.gz], [1.84e+09], [028b8c4edc3b], [028b8c4edc3b], [PASS], [SRR1166447],  
[JCYL003D], [cellobiose], [SRR1166447.fastq.gz], [1.59e+09], [cbb987dbfaa3], [cbb987dbfaa3],  
[PASS], )
```

4 实验设计

2 组 × 3 生物学重复，单一批次，厌氧指数期（起始糖 80 g/L，残余糖 ≈ 50 g/L 时取样）。原研究使用非配对两组比较；样本命名（JCYL001B/001D 等）暗示可能存在配对，但公开元数据无法确证。因此主分析采用非配对模型（~ condition），并以配对模型（~ replicate + condition）作敏感性分析。无 spike-in、无独立批次。

5 方法

步骤	工具、版本与参数
原始数据	ENA FTP 下载；md5 与 ENA 公布值逐一核对
读段 QC	FastQC 0.12.1；fastp 1.3.6（轻度修剪，保留长度 ≥ 36 bp）；MultiQC 1.35
参考（宿主）	RefSeq GCF_000146045.2（S288C R64-1-1，16 条染色体 + 线粒体）；用 gffread 0.12.9（抽取转录本；注释来自 SGD GAF（R64-5-1））

步骤 工具、版本与参数

参 考 (外 源)	宿主-载体-插入片段序列由样本 reads 自身裁决重建
定量	Salmon 2.7.0, decoy-aware 索引 (k = 31, 另做 k = 25 敏感性), -libType A -gcBias -seqBias; 片段长度先验设为实测读长 (49 bp)
基 因 水 平 矩阵	tximport 1.34.0, countsFromAbundance = lengthScaledTPM
差 异 表达	DESeq2 1.46.0; 主模型 ~ condition, 敏感性 ~ replicate + condition; apegglm 收缩 LFC 仅用于展示
多 重 检验	Benjamini-Hochberg
功 能 富集	clusterProfiler 4.14.0 (ORA + GSEA), TERM2GENE 自建; KEGG (sce) 结果缓存
报告	Quarto 1.9.38 (HTML 与 Typst 生成 PDF)

阈值: 主 DEG 为 BH 校正 $p < 0.05$ 且 $|\log_2FC| > 1$; 另报告放宽 ($p < 0.1$) 与收紧 ($p < 0.01$ 且 $|\log_2FC| > 1.5$) 两档, 以及与原文对齐的一档 ($FDR \leq 0.001$ 且 $|\log_2FC| \geq 1$)。所有阈值判定一律使用未收缩 (MLE) $\log_2FC$, apegglm 收缩值仅用于排序与作图。富集分析的背景集 (universe) 为检出表达的基因 (在 ≥ 3 个样本中 count ≥ 10), 共 6049 个。

6 质量控制

2014 年的数据为 Genome Analyzer II 单端 50 bp 读段。FastQC 判定为 Sanger/Illumina 1.9 编码, 因此无需 Phred64 处理。轻度修剪保留 2.386 亿 reads 中的 95.1%, Q30 由 0.88–0.93 提升至 0.93–0.96; adapter 残留可忽略 (修剪后约 150 reads/样本, 0.01%)。

read fate (读数去向) 按三级归因: (i) 端到端比对到宿主基因组 + 外源转录本 (94.5–95.5%); (ii) 对未比对部分做局部模式重比对 (可回收其中 19.9–22.8%, 源于端到端模式偏严与这批较老数据的读段错误); (iii) 用包含 pRS426 骨架、天然 2 μ 质粒与 TruSeq adapter 的诊断参考 (再解释残余的 35.6–40.4%)。仍有 2.2–3.0% (全库口径) 未能归因, 候选原因见“限制”一节。多映射比例为 23.0–24.9%, 主要由 Ty 元件与 rDNA 重复驱动; rDNA 位点是参考中覆盖最深的区域 (RD25-1 平均深度 23 $\times$)。

质粒拷贝数: 工程质粒骨架来源的 reads 在纤维二糖中为 1.65 倍 (每百万读数 10,385 $\rightarrow$ 17,188), 而天然 2 μ 质粒来源的 reads 不变 (3,358 $\rightarrow$ 3,012)。这独立说明拷贝数效应只发生在工程质粒上。

7 定量

宿主参考与注释已冻结 (RefSeq GCF_000146045.2、SGD 注释发布 R64-5-1, 全部文件记录 md5)。本数据集有两处必须特殊处理:

外源序列与文献所述并不一致。RNA-seq 样本携带的是 pRS426-BT, 其插入片段来自粗糙脉孢菌 cDNA。由 reads 重建的共识序列与 cdt-1 (NCU00801)、gh1-1 (NCU00130) 的公共 CDS 逐位一致 (0 处差异)。补充材料 Figure S8 中发表的密码子优化版本 gh1-1a 在样本中并不存在 (600 万 reads

中仅 2 条命中)，且与天然 CDS 有 25% 的位置不同——若直接用作参考，外源定量会被 静默破坏。C 端标签为 superfolder GFP：共识序列与人源化 EGFP CDS 仅差 7 个核苷酸，翻译后在 EGFP 骨架上带有全部 6 个 superfolder 替换（S30R/Y39N/N105T/Y145F/I171V/A206V）。cdt-1 与标签的接头由软剪切 reads 直接读出：...GTTGCT + ATCGAT (ClaI) + GGAGTGGTAGT (Gly-Ser-Gly-Ser) + GTGAGC...，与早期工作的克隆策略一致 [1]。由于外源参考的一部分来自样本 reads 自身，外源结果只报比值。

线粒体编码基因必须测量而非假设。RefSeq 的 RNA FASTA 不含线粒体蛋白编码 mRNA，因此改用 gffread 从 GFF 抽取转录本（6480 条宿主转录本，含 19 条线粒体 mRNA），再追加两条外源转录本。

Salmon 的 decoy-aware 索引比率为 80.0–83.5% ($k = 31$)；12 次运行均推断文库类型为非链特异性 (U)，与 TruSeq v1 建库一致。定量结果用三种独立方式验证：(i) TPM 与原文 RPKM 在 5796 个基因上 Spearman = 0.880；(ii) 加入或去掉基因组 decoy 对 TPM 的中位影响仅 0.027 个 log2 单位（5960 个基因中 17 个超过 1）；(iii) 两个标尺基因几乎逐位复现原文（URA3 比值 1.364 vs 1.354；PGK1 比值 0.749 vs 0.745）。

Salmon 2.7.0 (Rust 版) 报告的 **EffectiveLength** 语义异常：宿主转录本的中位有效长度为长度的 0.465 倍，外源条目则超过长度的 10 倍。这不影响上述结论——(i)–(iii) 的三项检验与 decoy 对照正是为界定该风险而做，且外源结论全部基于比值。

8 样本水平分析




图 1 Fig. 1 PCA of VST-normalised expression. Conditions separate on PC1 (93.4% of variance); within-condition replicates are tightly clustered (Spearman rho 0.994–0.998).




图2 Fig. 2 Sample-to-sample Spearman correlation of VST-normalised expression.

```
#table( columns: 2, table.header([item], [value]), [n_genes_used], [6049],
[PC1_var_pct], [93.4], [PC2_var_pct], [2.3], [within_glucose_spearman_min],
[0.996128331581355], [within_glucose_spearman_max], [0.997418249388038],
[within_cellobiose_spearman_min], [0.994419170799163], [within_cellobiose_spearman_max],
[0.997657475384432], [between_condition_spearman_min], [0.88554821526251],
[between_condition_spearman_max], [0.895435984222037], [separation_verdict], [conditions
separated on PC1], )
```

条件在 PC1 上分离 (93.4% 方差)，组内重复一致性极高 (Spearman ρ 0.994–0.998)，明显高于组间 (0.886–0.895)，支持 H0。

9 差异表达

```
#table( columns: 6, table.header([model], [n_tested], [n_deg], [n_up], [n_down], [n_transgene]),
[~condition (primary)], [6050], [ 644], [ 346], [ 298], [ 2], [~condition relaxed], [6050], [4580], [2320],
[2260], [ 2], [~condition stringent], [6050], [ 363], [ 207], [ 156], [ 2], [~condition FDR<=0.001 & |LFC|
```

>=1], [6050], [632], [341], [291], [2], [~replicate+condition (paired)], [6050], [643], [347], [296], [2],)

Volcano plot (n = 6048 genes; 644 DEGs at padj < 0.05 and |log2FC| >




图3 Fig. 3 Volcano plot of the primary model ($\sim \text{condition}$). Thresholds: BH-adjusted $p < 0.05$ and $|\log_2\text{FC}| > 1$; fold changes are unshrunk (MLE) values, which are the values used for all thresholding.

Top 50 DEGs (row-scaled VST)




图 4 Fig. 4 Row-scaled VST expression of the 50 most significant DEGs.




图 5 Fig. 5 p-value distribution of the primary model (no systematic anti-conservatism; Cook' s cutoff exceeded by 1 of 6049 genes).




图 6 Fig. 6 MA plot with apeglm-shrunken log2FC (display only; thresholding uses MLE values).

主模型得到 644 个 DEG (上调 346、下调 298); 与原文阈值对齐的一档得到 632 个 (341/291)。配对敏感性模型得到 643 个 DEG, 与主模型几乎完全一致 (Jaccard 0.986; 方向一致率 100%; log2FC 的 Pearson 相关 1.0000), 说明结论不依赖配对假设。模型诊断显示无系统性反保守, 仅 1 个基因超过 Cook' s distance 阈值。

10 功能富集

```
#table( columns: 6, table.header([comparison], [Description], [GeneRatio], [pvalue], [p.adjust],
[Count]), [primary_DOWN_GOslim], [amino acid metabolic process [GO:0006520]], [51/294],
[1.01e-24], [1.60e-22], [ 51], [primary_DOWN_GOslim], [small molecule metabolic process
[GO:0044281]], [86/294], [2.01e-23], [1.58e-21], [ 86], [primary_DOWN_GOslim], [sulfur
compound metabolic process [GO:0006790]], [35/294], [9.47e-19], [4.99e-17], [ 35],
[primary_DOWN_GOslim], [cytosol [GO:0005829]], [88/294], [1.14e-09], [4.51e-08], [ 88],
[primary_DOWN_GOslim], [transmembrane transporter activity [GO:0022857]], [42/294],
[1.30e-08], [4.11e-07], [ 42], [primary_DOWN_GOslim], [vitamin metabolic process [GO:0006766]],
[14/294], [1.71e-08], [4.50e-07], [ 14], [primary_DOWN_GOslim], [monoatomic ion transport
[GO:0006811]], [17/294], [2.07e-06], [4.31e-05], [ 17], [primary_DOWN_GOslim], [transmembrane
transport [GO:0055085]], [31/294], [2.18e-06], [4.31e-05], [ 31], [primary_UP_GOslim],
[respiratory chain complex [GO:0098803]], [36/316], [1.31e-41], [2.57e-39], [ 36],
[primary_UP_GOslim], [generation of precursor metabolites and energy [GO:0006091]], [50/316],
[1.65e-28], [1.62e-26], [ 50], [primary_UP_GOslim], [cellular respiration [GO:0045333]], [32/316],
```

[1.35e-21], [8.87e-20], [32], [primary_UP_GOslim], [mitochondrion [GO:0005739]], [120/316],
 [2.08e-18], [1.02e-16], [120], [primary_UP_GOslim], [proton-transporting ATP synthase complex
 [GO:0045259]], [14/316], [1.67e-17], [6.58e-16], [14], [primary_UP_GOslim], [oxidoreductase
 activity [GO:0016491]], [52/316], [8.83e-16], [2.90e-14], [52], [primary_UP_GOslim],
 [transmembrane transporter activity [GO:0022857]], [54/316], [4.87e-14], [1.37e-12], [54],
 [primary_UP_GOslim], [respiratory chain complex III [GO:0045275]], [9/316], [3.18e-12],
 [7.83e-11], [9], [threshold_matched_DOWN_GOslim], [amino acid metabolic process
 [GO:0006520]], [51/289], [4.39e-25], [6.93e-23], [51], [threshold_matched_DOWN_GOslim],
 [small molecule metabolic process [GO:0044281]], [86/289], [5.39e-24], [4.26e-22], [86],
 [threshold_matched_DOWN_GOslim], [sulfur compound metabolic process [GO:0006790]],
 [35/289], [5.37e-19], [2.83e-17], [35], [threshold_matched_DOWN_GOslim], [cytosol
 [GO:0005829]], [88/289], [4.33e-10], [1.71e-08], [88], [threshold_matched_DOWN_GOslim],
 [transmembrane transporter activity [GO:0022857]], [42/289], [7.74e-09], [2.45e-07], [42],
 [threshold_matched_DOWN_GOslim], [vitamin metabolic process [GO:0006766]], [14/289],
 [1.37e-08], [3.61e-07], [14], [threshold_matched_DOWN_GOslim], [transmembrane transport
 [GO:0055085]], [31/289], [1.51e-06], [3.22e-05], [31], [threshold_matched_DOWN_GOslim],
 [monoatomic ion transport [GO:0006811]], [17/289], [1.63e-06], [3.22e-05], [17],
 [threshold_matched_UP_GOslim], [respiratory chain complex [GO:0098803]], [36/315],
 [1.16e-41], [2.28e-39], [36], [threshold_matched_UP_GOslim], [generation of precursor
 metabolites and energy [GO:0006091]], [50/315], [1.41e-28], [1.39e-26], [50],
 [threshold_matched_UP_GOslim], [cellular respiration [GO:0045333]], [32/315], [1.22e-21],
 [8.03e-20], [32], [threshold_matched_UP_GOslim], [mitochondrion [GO:0005739]],
 [120/315], [1.54e-18], [7.59e-17], [120], [threshold_matched_UP_GOslim], [proton-transporting
 ATP synthase complex [GO:0045259]], [14/315], [1.60e-17], [6.29e-16], [14],
 [threshold_matched_UP_GOslim], [oxidoreductase activity [GO:0016491]], [52/315], [7.68e-16],
 [2.52e-14], [52], [threshold_matched_UP_GOslim], [transmembrane transporter activity
 [GO:0022857]], [54/315], [4.25e-14], [1.20e-12], [54], [threshold_matched_UP_GOslim],
 [respiratory chain complex III [GO:0045275]], [9/315], [3.09e-12], [7.61e-11], [9],)




图7 Fig. 7 GO slim over-representation analysis (top 10 terms per gene set; BH-adjusted p).

```
#table( columns: 6, table.header([ID], [Description], [GeneRatio], [pvalue], [p.adjust], [Count]),
[sce00190], [Oxidative phosphorylation - Saccharomyces cerevisiae (budding yeast)], [44/250],
[2.09e-26], [1.76e-24], [44], [sce01110], [Biosynthesis of secondary metabolites - Saccharomyces
cerevisiae (budding yeast)], [96/250], [1.67e-20], [7.00e-19], [96], [sce01230], [Biosynthesis of
amino acids - Saccharomyces cerevisiae (budding yeast)], [43/250], [9.83e-14], [2.75e-12],
[43], [sce00270], [Cysteine and methionine metabolism - Saccharomyces cerevisiae (budding
yeast)], [19/250], [2.73e-08], [5.74e-07], [19], [sce00340], [Histidine metabolism - Saccharomyces
cerevisiae (budding yeast)], [10/250], [1.26e-07], [2.12e-06], [10], [sce00670], [One carbon
pool by folate - Saccharomyces cerevisiae (budding yeast)], [12/250], [1.66e-06], [2.32e-05],
[12], [sce01200], [Carbon metabolism - Saccharomyces cerevisiae (budding yeast)], [29/250],
[3.21e-06], [3.86e-05], [29], [sce00920], [Sulfur metabolism - Saccharomyces cerevisiae (budding
yeast)], [9/250], [4.97e-06], [5.21e-05], [ 9], [sce01210], [2-Oxocarboxylic acid metabolism -
Saccharomyces cerevisiae (budding yeast)], [15/250], [1.03e-05], [9.65e-05], [15], [sce00220],
[Arginine biosynthesis - Saccharomyces cerevisiae (budding yeast)], [10/250], [1.29e-05],
[1.00e-04], [10], )
```

```
#table( columns: 6, table.header([ID], [Description], [setSize], [NES], [pvalue], [p.adjust]), [amino
acid metabolic process], [amino acid metabolic process], [222], [-2.65], [1.57e-23], [4.18e-20],
[carboxylic acid biosynthetic process], [carboxylic acid biosynthetic process], [181], [-2.65],
[1.63e-20], [1.45e-17], [organic acid biosynthetic process], [organic acid biosynthetic process],
[181], [-2.65], [1.63e-20], [1.45e-17], [alpha-amino acid metabolic process], [alpha-amino acid
metabolic process], [159], [-2.66], [3.33e-19], [2.22e-16], [L-amino acid metabolic process], [L-
amino acid metabolic process], [147], [-2.64], [2.95e-18], [1.13e-15], [proteinogenic amino acid
```

metabolic process], [proteinogenic amino acid metabolic process], [147], [-2.64], [2.95e-18], [1.13e-15], [small molecule biosynthetic process], [small molecule biosynthetic process], [343], [-2.32], [2.88e-18], [1.13e-15], [amino acid biosynthetic process], [amino acid biosynthetic process], [119], [-2.65], [2.08e-17], [6.94e-15], [sulfur compound metabolic process], [sulfur compound metabolic process], [146], [-2.59], [1.02e-16], [3.02e-14], [organic acid metabolic process], [organic acid metabolic process], [354], [-2.23], [5.53e-16], [1.47e-13],)

原文使用 FunSpec + Bonferroni (p 0.01) ; 本重分析使用 clusterProfiler + Benjamini-Hochberg, 并自建 GO slim 映射 (SGD [go_slim_mapping.tab](#)) 以及经 true-path-rule 传播到祖先术语的全 GO 注释。富集过程的身份与方向复现了原文结论: 上调基因由呼吸链、氧化磷酸化、ATP 合成、线粒体与 TCA 循环 相关术语主导; 下调基因由氨基酸生物合成 (Met、Cys、Arg、His) 与硫胺素 (维生素 B1) 生物合成 主导; KEGG 结果同向 (氧化磷酸化、氨基酸生物合成、半胱氨酸与甲硫氨酸代谢、组氨酸代谢)。

一项原研究未报告的观察: GSEA 负向最强的信号集中在 Ty 逆转座子相关术语。由于这些序列高度多映射, 该结果仅谨慎陈述, 且不用于任何生物学结论。

11 生物学解读

```
#table( columns: 7, table.header([hypothesis_id], [n_subtests], [n_subtests_replicated],  
[n_subtests_not_replicated], [n_subtests_contradicted], [n_subtests_not_assessable],  
[hypothesis_verdict]), [H0], [1], [1], [0], [0], [0], [replicated], [H1], [5], [5], [0], [0], [0], [replicated],  
[H2], [6], [6], [0], [0], [0], [replicated], [H3], [3], [1], [2], [0], [0], [replicated (partial activation, as  
originally reported)], [H4], [1], [1], [0], [0], [0], [replicated], [H5], [2], [1], [1], [0], [0], [replicated],  
[H6], [1], [1], [0], [0], [0], [replicated], [H7], [1], [1], [0], [0], [0], [replicated], [H8], [3], [3], [0], [0], [0],  
[replicated], [H9], [1], [1], [0], [0], [0], [replicated], )
```

```
#table( columns: 7, table.header([hypothesis], [n_genes], [mean_log2FC], [wilcoxon_p],  
[n_deg_in_set], [fisher_p], [verdict]), [H0: global transcriptome separates by carbon source],  
[6050], [NA], [NA], [NA], [NA], [replicated], [H7: transgene mRNA is higher on cellobiose (ratio-  
based, pre-registered)], [ 2], [NA], [NA], [ 2], [NA], [replicated], [H1: TCA cycle (GO:0006099)], [ 28],  
[ 0.859], [ 1.94e-04], [11], [8.11e-05], [replicated], [H1: electron transport chain (GO:0022900)],  
[ 40], [ 1.550], [ 1.81e-08], [29], [3.88e-20], [replicated], [H1: oxidative phosphorylation  
(GO:0006119)], [ 37], [ 1.790], [ 4.80e-10], [29], [7.45e-22], [replicated], [H1: ATP synthesis coupled  
proton transport], [ 16], [ 1.790], [ 3.05e-05], [15], [2.94e-14], [replicated], [H1: respiratory chain  
complex (GO:0098803)], [ 45], [ 1.910], [ 1.14e-13], [38], [1.22e-30], [replicated], [H2: cellular  
amino acid biosynthetic process], [ 119], [-0.818], [ 2.46e-11], [50], [1.58e-17], [replicated],  
[H2: methionine biosynthetic process], [ 26], [-1.330], [ 1.91e-05], [13], [6.54e-07], [replicated],  
[H2: cysteine biosynthetic process], [ 5], [-2.170], [ 6.25e-02], [ 3], [1.00e-02], [replicated], [H2:  
arginine biosynthetic process], [ 13], [-1.480], [ 1.22e-03], [10], [3.58e-08], [replicated], [H2:  
histidine biosynthetic process], [ 8], [-1.060], [ 1.56e-02], [ 6], [3.23e-05], [replicated], [H2:  
thiamine biosynthetic process], [ 16], [-1.220], [ 2.69e-03], [ 7], [7.64e-04], [replicated], [H3:  
PKA pathway], [ 10], [ 0.448], [ 3.91e-03], [ 0], [6.13e-01], [replicated], [H3: Snf3-Rgt2-Rgt1], [ 5],  
[ 0.047], [ 1.00e+00], [ 2], [9.06e-02], [not_replicated], [H3: Snf1-Mig1], [ 5], [-0.054], [ 8.12e-01],  
[ 1], [4.30e-01], [not_replicated], [H4: hexose transporters], [ 11], [-0.138], [ 9.66e-01], [ 6],  
[4.13e-04], [replicated], [H5: SUT1 + ERG sterol genes], [ 21], [ 0.058], [ 7.85e-01], [ 2], [1.00e+00],  
[not_replicated], [H5: DAN/TIR/PAU family], [ 26], [ 0.580], [ 3.34e-02], [12], [6.01e-06], [replicated],  
[H6: storage carbon & gluconeogenesis], [ 8], [ 1.120], [ 2.34e-02], [ 2], [2.07e-01], [replicated],
```

[H9: ribosomal protein genes (growth-rate proxy)], [132], [0.337], [1.36e-21], [1], [4.58e-07], [replicated], [H8: YGL162W (engineering candidate from H3/H5)], [1], [2.140], [2.83e-272], [NA], [NA], [replicated (differentially expressed)], [H8: YKL109W (engineering candidate from H3/H5)], [1], [2.630], [7.07e-265], [NA], [NA], [replicated (differentially expressed)], [H8: YKR034W (engineering candidate from H3/H5)], [1], [1.220], [5.53e-52], [NA], [NA], [replicated (differentially expressed)],)

```
#table( columns: 6, table.header([estimator], [gene], [glucose_value], [cellobiose_value], [FC],
[note]), [salmon_CPM], [cdt-1EGFP], [2260.0], [4530.0], [2.010], [每百万映射读数的均值],
[salmon_CPM], [gh1-1], [1400.0], [3260.0], [2.320], [每百万映射读数的均值], [salmon_TPM],
[cdt-1EGFP], [ 26.8], [ 75.7], [2.820], [TPM (长度归一化) ], [salmon_TPM], [gh1-1], [ 26.4], [ 84.4],
[3.190], [TPM (长度归一化) ], [URA3_proxy], [URA3(YEL021W)], [ 432.0], [ 589.0], [1.360], [质粒拷
贝数代理 (原文锚定 1.354) ], [PGK1_control], [PGK1(YCR012W)], [NA], [NA], [0.749], [同启动子反证
(原文锚定 0.745) ], [URA3_normalized], [cdt-1EGFP], [NA], [NA], [1.470], [= CPM_FC / URA3_FC],
[URA3_normalized], [gh1-1], [NA], [NA], [1.700], [= CPM_FC / URA3_FC], [original_RPKM],
[cdt-1EGFP], [ 877.0], [1640.0], [1.870], [原文 Dataset S1 锚定值], [original_RPKM], [gh1-1], [ 932.0],
[2010.0], [2.160], [原文 Dataset S1 锚定值], [reads_1M_subsample], [cdt-1], [1390.0], [2630.0],
[1.880], [裁决实验 bowtie2 读数 (PLAN 3.4.3) ], [reads_1M_subsample], [gh1-1], [1200.0], [2680.0],
[2.220], [裁决实验 bowtie2 读数 (PLAN 3.4.3) ], )
```

Transgene and plasmid-copy-number proxy: independent estimators




图 8 Fig. 10 Independent estimators of the transgene fold change (cellobiose/glucose) and of the plasmid copy-number proxy URA3. Read-based estimators (1.89-2.01 for cdt-1EGFP, 2.22-2.32 for gh1-1) bracket the values reported in the original study (1.87 and 2.16).

九条预注册假设均以集合水平统计量判定 (Wilcoxon 符号秩检验、Fisher 精确检验的差异表达富集、集合内 DEG 计数)。全部获得支持：

- H1 (线粒体功能激活) 在五个独立基因集上复现 (呼吸链复合物 +1.91; ATP 合成 +1.79, 16 个基因中 15 个为 DEG; 氧化磷酸化 +1.79; 电子传递链 +1.55; TCA 循环 +0.86)。线粒体编码基因被排除在该检验之外 (见”限制”)。
- H2 (氨基酸与硫胺素合成下调) 在全部六个子集复现, 包括硫胺素生物合成 (-1.22; 16 个中 7 个 DEG, Fisher $p = 2.7 \times 10^{-3}$)。
- H3 (葡萄糖信号通路仅部分激活) 在原研究所述的意义上成立: PKA 集合仅小幅偏移 (+0.45), Rgt1 与 Snf1-Mig1 集合无系统性偏移。
- H4 (己糖转运蛋白家族重排) 整体无方向性偏移 (平均 $\log_2FC -0.14$), 但 11 个转运蛋白中有 6 个为 DEG, 属”家族级重排”而非一致响应。
- H5-H8 均复现, 包括工程线索: SUT1 +1.77、HAP4 +2.61、DAL80 +1.22。
- H9 (生长速率/葡萄糖阻遏混杂): 核糖体蛋白基因集 (132 个) 整体 +0.34 ($p = 1.4 \times 10^{-21}$), 说明混杂确实存在且可测量; 其方向提示主轴是葡萄糖阻遏解除而非”慢生长”——因为酵母中核糖体蛋白基因通常随生长速率升高而上调。

12 与原研究的一致性

```
#table( columns: 2, table.header([metric], [value]), [genes_comparable_FC], [5770.000],  
[spearman_log2FC], [ 0.973], [pearson_log2FC], [ 0.840], [our_DEG_threshold_matched],  
[ 632.000], [original_DEG], [ 519.000], [overlap], [ 496.000], [jaccard], [ 0.757], [hypergeometric_p],  
[ 0.000], [direction_concordance_in_overlap], [ 1.000], [background_genes], [5780.000], )
```




图 9 Fig. 8 Per-gene log2FC agreement with the original study (Spearman = 0.973 over 5771 genes).




图 10 Fig. 9 Precision/recall of the original 519 DEGs as a function of threshold.

#table(columns: 2, table.header([item], [reason]), [mtDNA-encoded gene expression], [poly-A selection captures yeast mitochondrial transcripts inefficiently; 5-18 chrM reads per 1e6; 0/19 mt genes reach 1x], [absolute transgene abundance], [the tag/junction part of the transgene reference is derived from the sample reads themselves (circularity)], [absolute RPKM/TPM matching the original], [CLC multi-mapping and ‘By totals’ RPKM are not reproducible outside CLC; only gene-level trends are comparable], [cross-tool mapping statistics], [original 92.3/83.4/76.3% were produced by CLC’ s internal algorithms; only order-of-magnitude comparison is meaningful], [transgene C-terminal His6 cleavage state], [requires protein-level data, out of scope],)

#table(columns: 4, table.header([item], [value], [note], [check]), [dataset_s1_rows_total], [6350], [Dataset S1 数据行数 (含 2 条外源)], [ok], [dataset_s1_host_genes], [6350], [宿主基因条目数], [ok], [dataset_s1_transgenes], [2], [外源条目数 (cdt-1EGFP, gh1-1)], [ok], [dataset_s2_deg_rows], [519], [原文报告的 519 个 DEG], [ok], [dataset_s2_deg_transgenes], [1], [519 中的外源条目数 (gh1-1)], [ok], [dataset_s2_tf_rows], [19], [19 个转录因子], [ok], [dataset_s2_grn_rows], [7], [7 个 GRN 调控基因], [ok], [dataset_s3_go_terms_up], [12], [UP 侧 GO 条目数], [ok], [dataset_s3_go_terms_down], [16], [DOWN 侧 GO 条目数], [ok], [dataset_s3_up_genes], [244], [Dataset S3 区块标题声明的 UP 基因数], [ok], [dataset_s3_down_genes], [256], [Dataset S3 区块标题声明的 DOWN 基因数], [ok], [dataset_s3_notfound_up], [3], [FunSpec UP 未映射基因数], [ok], [dataset_s3_notfound_down], [0], [FunSpec DOWN 未映射基因数], [ok], [check_sum_of_parts], [503], [对账: UP + DOWN + 两侧 not found], [ok], [check_gap_vs_519], [16], [与 519 的差额; 需在报告 5.12 解释 (候选: 外源条目 gh1-1 无 GO 注释)], [ok],)

在所有可比较的层面，一致性都很高：

层面	结果
逐基因 log2FC (5771 个基因)	Spearman 0.973, Pearson 0.840
DEG 重叠 (632 vs 原文 519)	重叠 496, Jaccard 0.757, 超几何 $p \approx 0$
重叠内方向一致率	100%
数字对账	原文 519 = 244 上调 + 256 下调 + 18 未映射 + gh1-1 (无 GO 注释)
外源倍数变化 (比值口径)	1.89–2.01 (cdt-1EGFP)、2.22–2.32 (gh1-1), 原文为 1.87 与 2.16
质粒拷贝数代理 (URA3)	1.364, 原文 1.354

RPKM/TPM 的绝对值无法与原文一致：CLC 内部的多重比对处理在 CLC 之外不可复现（原文也仅有 76.3% 唯一比对），92.3/83.4/76.3% 这类比例是软件特有量。可复现的是基因水平趋势，而这一趋势几乎被逐位复现。

13 限制

- 富集框架与原文不同 (clusterProfiler + BH vs FunSpec + Bonferroni)，因此富集 p 值不可直接比较，可比较的是富集过程的身份与方向。
- 线粒体编码基因不可评估：poly-A 富集对其捕获效率极低 (每百万读数仅 5–18 条 chrM reads；19 个线粒体基因无一达到 $1\times$ 覆盖)。这与芽殖酵母线粒体 mRNA 缺乏可供 oligo(dT) 捕获的长 poly(A) 尾一致 [3]。因此 H1 只在核编码线粒体功能基因范围内检验。
- 外源丰度存在一定循环性：标签与接头序列来自样本 reads 自身。比值对此稳健（两个条件使用同一参考、偏差同向），但绝对 TPM 不可独立验证。
- 质粒拷贝数在条件间不同 (URA3 $1.364\times$ ；骨架 reads $1.65\times$)。用代理指标归一化后，外源比值降至 1.47 (cdt-1EGFP) 与 1.70 (gh1-1)，即部分升高来自拷贝数而非转录调控。
- 质粒终止子/启动子串扰对 PGK1 与 CYC1 影响很小但无法完全分离；CYC1 本身是线粒体激活相关基因，在原文数据中变化 2.5 倍。
- 未比对 reads 仅部分解释：仍有 2.2–3.0% (全库口径) 未归因，候选原因包括 GA II 数据的读段错误、非酵母污染、R64 组装中塌缩或缺失的区域（亚端粒/Y' 元件），以及在任何参考中都不存在的嵌合 reads（启动子–CDS、CDS–终止子）。
- 无 spike-in、无独立批次、 $n = 3$ ，限制绝对定量与方差估计；6 个样本下替代变量方法不适用。
- Salmon 2.7.0 的 **EffectiveLength** 语义异常（见“定量”），已证明结论对其不敏感，但绝对 TPM 不宜过度解读。
- 配对关系无法确证，配对模型仅作为敏感性分析。

14 工程含义

本重分析复现了原研究的两条工程线索并给出量化语境：SUT1 (+1.77) 与 HAP4 (+2.61) 是最强烈诱导的转录因子之列，DAL80 (+1.22) 同样显著。需要注意 HAP4 在纤维二糖中上调，而其缺失改善发酵，说明其调控作用非单调——这提醒不能把转录方向直接当作工程指令。响应主体集中在酵母线粒体功能与氨基酸/硫胺素途径，提示面向辅因子与前体供给（而非仅糖转运）的工程策略更具前景。

15 可复现性

本报告全部内容由 `scripts/` 下的编号脚本生成：

```
conda env create -f environment.yml && conda activate yeast-cellobiose-rnaseq
bash run_all.sh          # 幂等；已完成步骤自动跳过
```

凭证	位置
原始数据校验（自算 + ENA 公布）	checksums/
参考与注释版本	refs/VERSIONS.md
全部非公开序列的来源	refs/custom/PROVENANCE.md
序列裁决与接头证据	refs/custom/ {sequence_adjudication.tsv,junctions.tsv}
环境锁（conda-explicit + R 包快照）	env/
参数与范围决策	docs/decisions/
阶段验收记录	docs/acceptance/

R 环境以 `conda` 而非 `renv` 锁定，因为在本机配置下 `renv` 的项目激活会遮蔽 `conda` 库（见 `docs/decisions/r_environment.md`）。

16 结论

用独立、完全脚本化的流程重分析 GSE54825，在”可比较”的层面上几乎完整复现了原研究：逐基因倍数变化的排序一致性 97.3%，找回原文 519 个 DEG 中的 496 个，方向一致率 100%，富集过程一致。另有三点超出原文：外源参考序列由数据重建并验证（发现已发表的密码子优化版本 `gh1-1a` 并非本样本中的等位基因）；量化了质粒拷贝数对外源信号的贡献；把”生长速率/葡萄糖阻遏”混杂从假设变为测量。无法消除的限制——线粒体编码基因、外源绝对丰度、CLC 特有的映射统计——均被明确声明。

参考文献

参考文献

[1] J. M. Galazka, C. Tian, W. T. Beeson, B. Martinez, N. L. Glass, 和 J. H. D. Cate, 《Cellodextrin transport in yeast for improved biofuel production》, Science, 卷 330, 期 6000, 页 84~86, 2010, doi: 10.1126/science.1192838.

[2] Y. Lin 等 , 《 Leveraging transcription factors to speed cellobiose fermentation by *Saccharomyces cerevisiae*》 , Biotechnology for Biofuels, 卷 7, 页 126, 2014, doi: 10.1186/s13068-014-0126-6.

[3] D. D. Chang 和 A. H. Tong, 《Mitochondrial poly(A) polymerase and polyadenylation》 , Biochimica et Biophysica Acta, 卷 1819, 页 945~950, 2012, doi: 10.1016/j.bbagr.2012.01.008.